Tanvir's Blog
Tanvir Hasan, Uap

KMP (Knuth-Morris-Pratt algorithm)

Posted on March 3, 2015

3 Votes

KMP কি?

kmp স্ট্রিং ম্যাচিং এ্যালগরিদম। Kmp লিনিয়ার টাইমে একটা স্ট্রিং T তে একটা প্যাটার্ন স্ট্রিং P কতবার আছে এবং কোন কোন পজিশনে আছে তা বের করে।

KMP কিভাবে কাজ করে?

Kmp কিভাবে কাজ করে তা বুঝার আগে একটা স্ট্রিং T থেকে প্যাটার্ন স্ট্রিং P কতবার ও কোথায় আছে তার naive solution টা দেখে নেয়া জরুরী।

```
#include<bits/stdc++.h>
char T[10000];
char P[10000];
int main()
{
    scanf("%s %s",T,P);
    for(int i=0;T[i];i++)
    {
        bool flag=true;
        for(int j=0;P[j];j++)
        {
            if(P[j]!=T[i+j])
            {
                flag=false;
                break;
            }
        }
        if(flag)std::cout<<"match at position "<<i<<std::endl;
    }
    return 0;
}
```

উপরে solution এ T এর প্রতি পজিশন থেকে P স্ট্রিং ম্যাচ করে দেখা হচ্ছে এবং কোথাও ম্যাচ না পেলে আবার P স্ট্রং এর প্রথম পজিশনে গিয়ে ম্যাচ করে দেখা হচ্ছে।
Kmp এ্যালগরিদম ম্যাচ না পেলে P স্ট্রিং এর বার বার প্রথম পজিশন এ গিয়ে ম্যাচ করানোর জিনিস টা স্কিপ করে।
Kmp এ্যালগরিদমে একটা ফাংশন থাকে যাকে prefix/π/failure ফাংশন বলা হয়ে থাকে।
এই ফাংশন একটা π এ্যারে তৈরী করে দেয়, যাতে প্যাটার্ন স্ট্রিং P এর সব পজিশনে কতটুক প্রিফিক্স ম্যাচ করে তা থাকে।
যখনেই T স্ট্রিং এর কোন পজিশন এ P এর স্ট্রিং এর কোন পজিশন মিস ম্যাচ হবে, তখন π এ্যারে দেখে P স্ট্রিং এর কোন পজিশনে যাবে তা নির্ধারন করা হয়।
ধরা যাক P স্ট্রিং $[P_1P_2,P_3,P_4,P_5,P_6]$ এর π এ্যারে [0,0,1,2,3,0,1] এমন।
এখন একটা T স্ট্রিং আছে $[X_1X_2,X_3,X_4,X_5,X_6,X_7,X_8,X_9,X_{10},X_{11},X_{12},X_{13}]$ এমন।

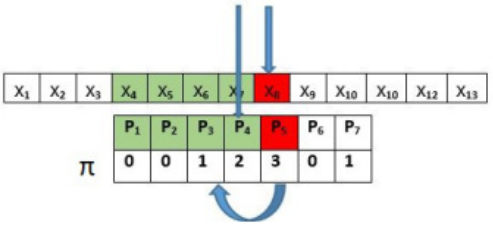

এখন T স্ট্রিং এর সাথে P স্ট্রং ম্যাচ করতে করতে $x_{8,}P_5$ মিস ম্যাচ হল, তাহলে $\pi[5]$ পজিশন এ জাম্প করবে এবং দেখবে P স্ট্রিং এর পরের পজিশন T এর current পজিশনের সাথে ম্যাচ করে নাকি। যদি ম্যাচ করে তাহলে পরবর্তী সার্চ সেখান থেকে শুরু হবে। কারন আমি T স্ট্রিং এর সাথে P স্ট্রং এর $\pi[5]$ পর্যন্ত প্রিফিক্স ম্যাচ করে আসেছি। আর যদি ম্যাচ না করে তাহলে সেই পজিশনের π পজিশনে আবার জাম্প করবে ঠিক করবে কোথায় থেকে ম্যাচিং শুরু করবে।

Compute Prefix/Failure function:

Here Green character need to match, Red character mismatch, Blue character match.

Pattern string: “ababaca”

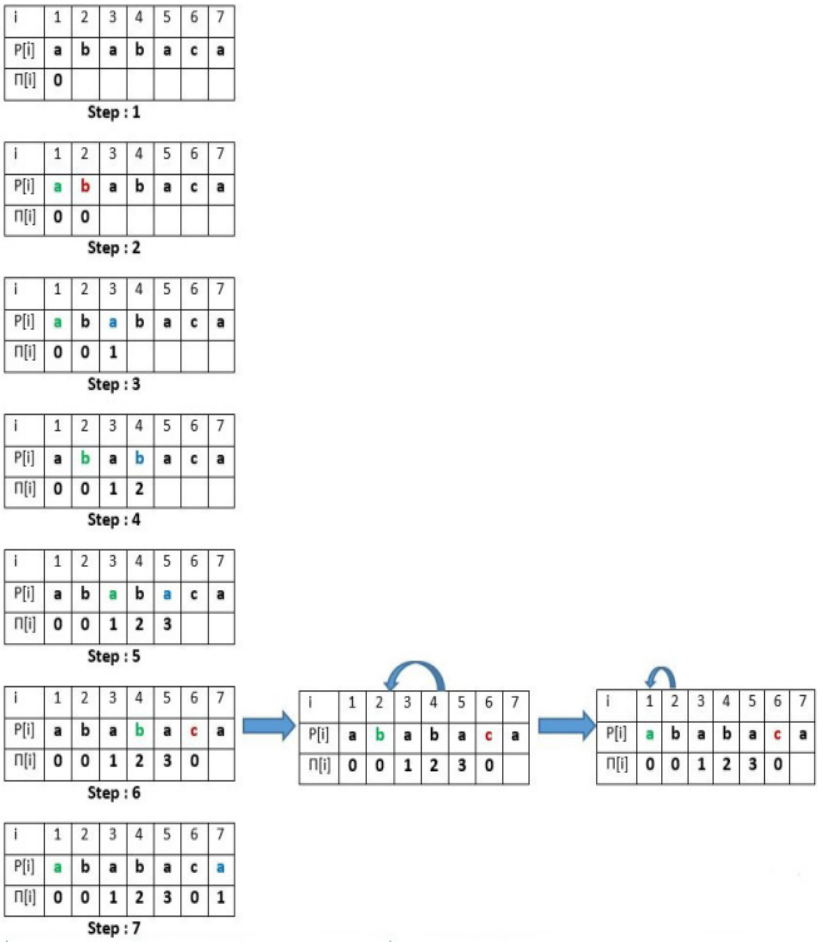

π array calculation steps:

```
vector<int> compute_prefix
{
    int m=strlen(p+1);
    vector<int> prefix(m+1
    prefix[1]=0;
    int k=0;
    for(int i=2; i<=m; i++
```

```
        {
            while(k>0 and p[k+
            if(p[k+1]==p[i])k=
            prefix[i]=k;
        }
        return prefix;
    }
```


KMP-Matcher:

Here Blue part current matching, Green part previously match and Red part current mismatch.

Text String T=”abababababacaab”, Pattern String P=”ababaca”

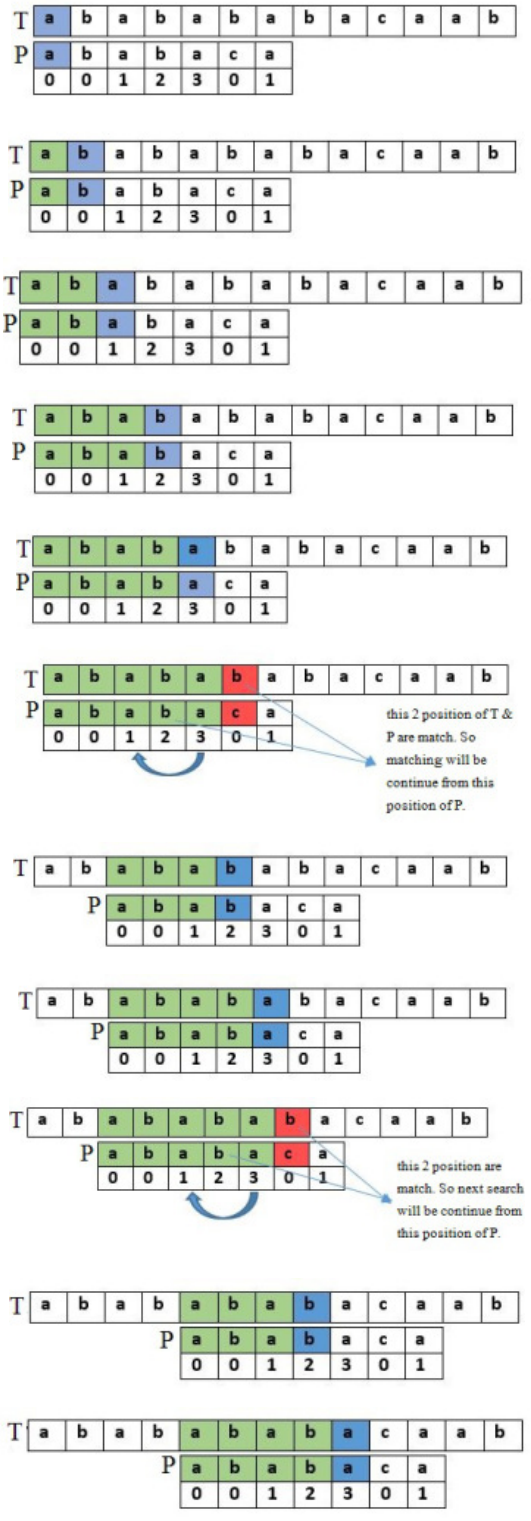

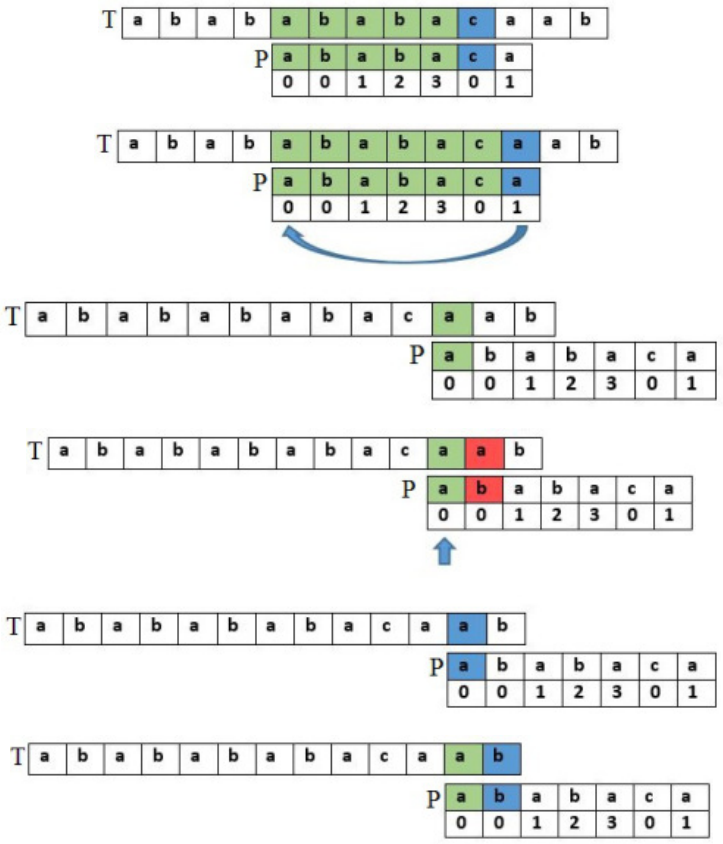


```
vector<int> KMP_match(const char *txt,const char *ptrn)
{
    int n=strlen(txt+1);
    int m=strlen(ptrn+1);
    vector<int> Prefix=compute_prefix(ptrn);
    vector<int>Match_position;
    int q=0;
    for(int i=1; i<=n; i++)
    {
        while(q>0 and ptrn[q+1]!=txt[i])q=Prefix[q];
        if(ptrn[q+1]==txt[i])q=q+1;
        if(q==m)
        {
            Match_position.push_back(i-m);
            q=Prefix[q];
        }
    }
    return Match_position;
}
```

Complexity analysis:

Compute prefix function এ লাইন 9 while loop execute হবে O(m) times. এখন k=0 এবং 7-12 লাইনে for loop এ k সর্বোচ্চ প্রতিবার বাড়তে পারে আর k এর সর্বোচ্চ মান মনে m-1।
আবার k<i এবং $\pi[i]$
দেখা যাচ্ছে while loop এর প্রতি iteration এ k time decrease হচ্ছে।
তারমানে পুরো for loop এ while loop total m-1 time iterate হচ্ছে। সুতরাং prefix function er runtime হচ্ছে, $\Theta(m)$।
একইভাবে kmp matcher function এর runtime analysis করা যায় $\Theta(n)$।
সুতরাং kmp algorithm এর total complexity: $\Theta(n+m)$.

All together:

```
#include<bits/stdc++.h>
using namespace std;
char TXT[10000000],ptr[10000000];
vector<int> Match_position;
vector<int> compute_prefix(const char *p)
{
    int m=strlen(p+1);
    vector<int> prefix(m+1);
    prefix[1]=0;
    int k=0;
    for(int i=2; i<=m; i++)
    {
        while(k>0 and p[k+1]!=p[i])k=prefix[k];
        if(p[k+1]==p[i])k=k+1;
        prefix[i]=k;
    }
    return prefix;
}
vector<int> KMP_match(const char *txt,const char *ptrn)
{
    int n=strlen(txt+1);
    int m=strlen(ptrn+1);
    vector<int> Prefix=compute_prefix(ptrn);
    vector<int>Match_position;
    int q=0;
    for(int i=1; i<=n; i++)
    {
        while(q>0 and ptrn[q+1]!=txt[i])q=Prefix[q];
        if(ptrn[q+1]==txt[i])q=q+1;
        if(q==m)
        {
            Match_position.push_back(i-m);
            q=Prefix[q];
        }
    }
    return Match_position;
}
int main()
{
    scanf("%s %s",TXT+1,ptr+1);
    vector<int> Match_position=KMP_match(TXT,ptr);
    for(int i=0; i<Match_position.size(); i++)
    {
        if(!i)printf("%d",Match_position[i]);
        else printf(" %d",Match_position[i]);
    }
    return 0;
}
```

ইনপুট নেয়া লাগবে index 1 থেকে।

Reference:

1. Introduction to Algorithms – Cormen
2. wiki

Practice problem:

1. Ministry of Truth
2. Jack's Last Word
3. Substring Frequency

4. Making Huge Palindromes

বিদ্রঃ কোথায় ভুল থাকলে বা বুঝতে সমস্যা হলে কমেন্টে জানানোর জন্য অনুরোধ করা হল।

Happy Coding

Share this:

About Tanvir Hasan Anick

I can read and write code, :)

View all posts by Tanvir Hasan Anick →

This entry was posted in algorithm and tagged algorithm, String. Bookmark the permalink.

One Response to *KMP (Knuth-Morris-Pratt algorithm)*

Rajon Bardhan *says:*

March 5, 2015 at 6:31 pm

The Pictures are very helpful .
Thanks .

★ Liked by 1 person

3 0 Rate This

Reply